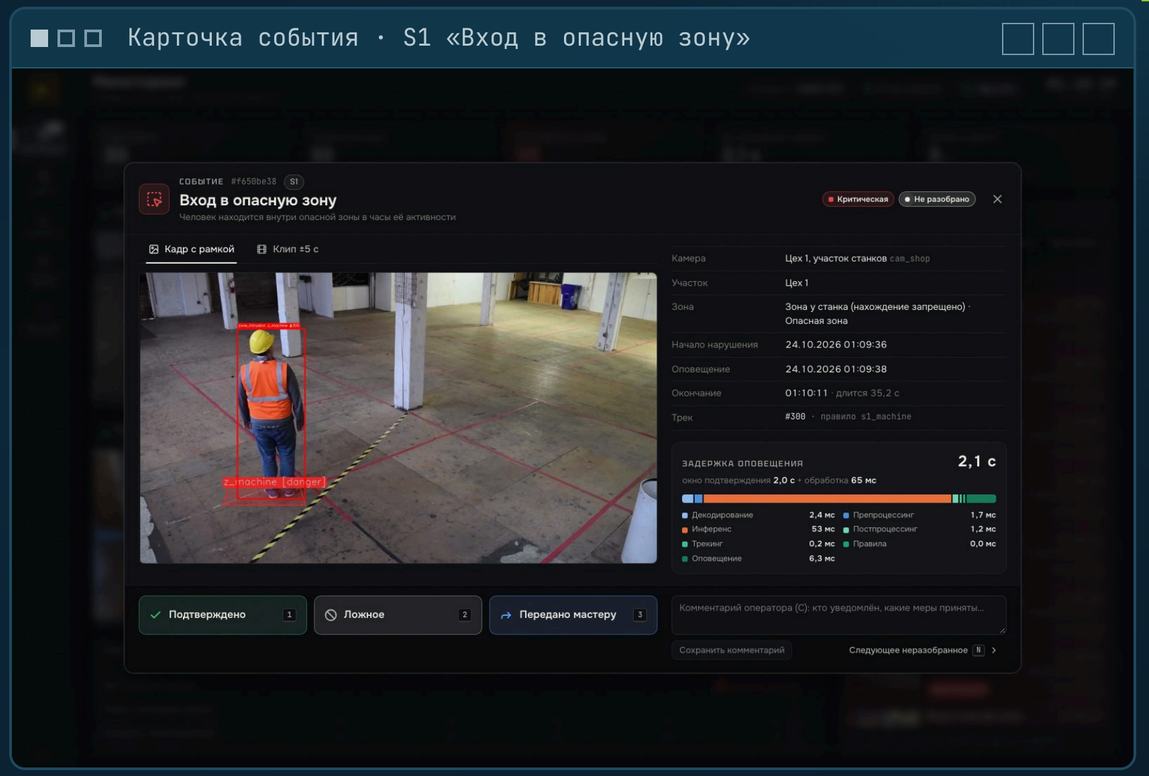
ХАКАТОН «ОТКРОЙ#МОСПРОМ» · КЕЙС LINQ

# Зазеркалье

## Одно нарушение — одно оповещение. На LinQ TPU.

Веб-сервис видеоаналитики техники безопасности в реальном времени. Камеры уже стоят — превращаем архив в систему предупреждения.

- 10 типов нарушений — 10 плагинов
- edge-узел рядом с LinQ TPU
- оповещение через 2.2 с (p50)
- замкнутый цикл качества




Одна карточка на нарушение: кадр с рамкой, клип ±5 с, камера, зона, время, задержка по этапам. Оператор решает клавишей 1 / 2 / 3.

Команда «Зазеркалье» · Защита 25.10.2026

Источник: Скриншот: живой бэкенд на ноутбуке, режим local, CPU, 24.10 01:09 · deliverables/screens/real-02-event-card.jpg · цифры: docs/EDGE.md §6.1, docs/QUALITY.md

ПРОБЛЕМА О · А

# Камеры пишут архив. Разбор — уже после инцидента

**20-30 мин**

через столько падает внимание оператора у стены мониторов

кейс LinQ, слайд 3

**20.8 тыс.**

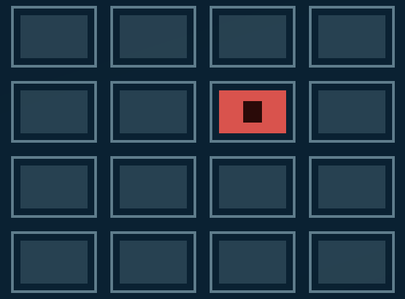
пострадавших при несчастных случаях на производстве в РФ за 2025 год

Росстат, 2025

**1.07 тыс.**

из них — со смертельным исходом

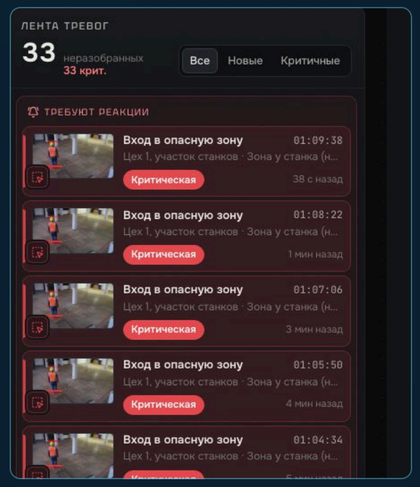
Росстат, 2025



нарушение на 1 экране из 16 — никто не смотрит

## Сейчас

- Камеры — архив: видео смотрят, когда инцидент уже случился
- Контроль выборочный: инженер ОТ не может быть на всех участках
- Ложные тревоги убивают доверие, дубли забивают ленту



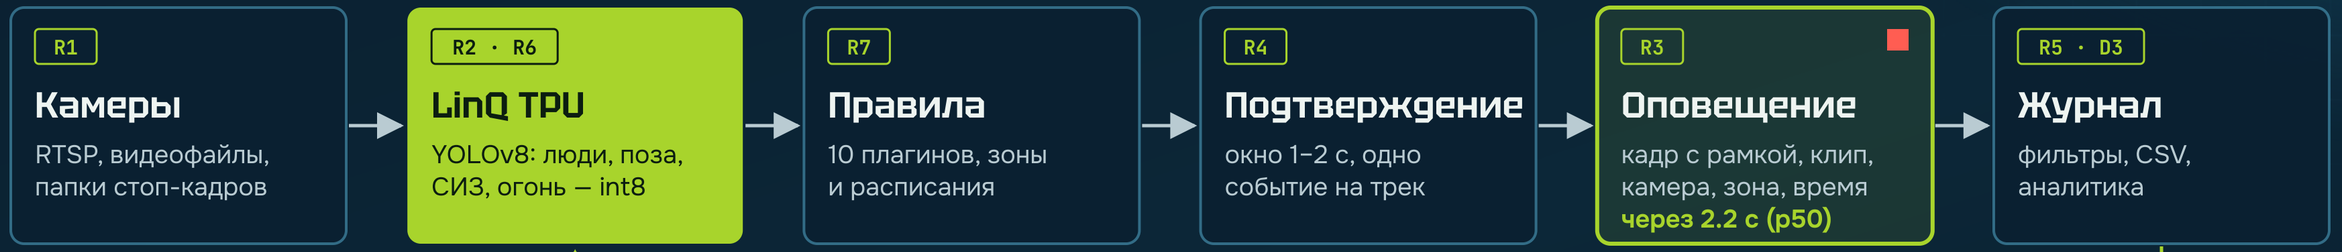

## С «Зазеркальем»

- Лента событий вместо стены мониторов, критичные — сверху и со звуком
- Одно нарушение — одно оповещение: кадр, клип, камера, зона, время
- 2.2 с (p50) от начала нарушения до оповещения — замер на стенде LinQ

Источник: Кейс LinQ, слайды 2-3, 7 · Росстат, «Производственный травматизм», pr_travm_2025.xlsx · docs/ANALYTICS.md §1.3, §2 · задержка: docs/EDGE.md §6.1

КЕЙС → РЕШЕНИЕ П·О

# Требования кейса R1-R7 — в одном конвейере




пунктир — замкнутый цикл качества, слайд 10

R1 · потоки
**4 камеры**
одновременно на edge-узле, 4.8–4.9 к/с каждая

R2 · нейросети
**4 модели**
YOLOv8: люди и техника, поза, СИЗ, огонь

R3 · оповещение
**2.2 с**
p50 от начала нарушения до оповещения, TPU

R4 · одно на нарушение
**0 дублей**
на 13 размеченных роликах

R5 · журнал
**6 фильтров**
период, тип, камера, зона, статус, важность; CSV

R6 · LinQ TPU
**45.7 к/с**
YOLOv8n det 480; в 4.9–7.1 раза больше CPU

R7 · модули
**1 файл**
на новый тип нарушения; сейчас 10 плагинов

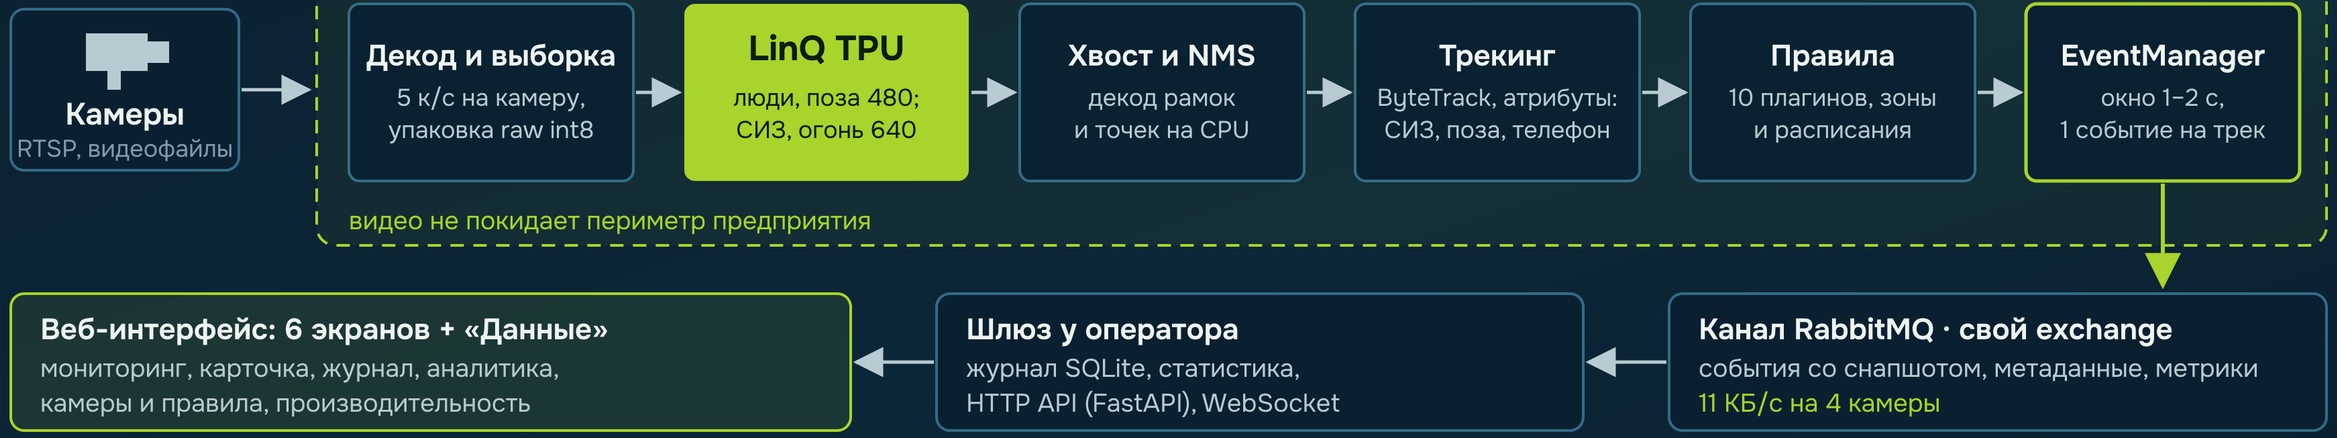
ЖЕЛАТЕЛЬНОЕ **D1** зоны и расписания из UI **D2** подавление повторов **D3** дашборд **D4** статусы оператора **D5** несколько потоков на узле

Источник: Требования R1-R7, D1-D5 — кейс LinQ · как закрыты — docs/EXPERT_CALL.md §2 · цифры: docs/EDGE.md §6.1, docs/QUALITY.md, docs/BENCHMARKS.md §1-2, docs/ARCHITECTURE.md §6

АРХИТЕКТУРА П · В

# Видео остаётся на площадке — наружу только события

EDGE-УЗЕЛ LINQ НА ПЛОЩАДКЕ




## ПОЧЕМУ РЯДОМ С TPU

С ноутбука через VPN — **3305 мс**

Рядом с TPU, на стенде — **40.5 мс**

кадр YOLOv8n det 480 на TPU, total p50 · вход 2.76 МБ, канал от стенда 0.1–0.4 МБ/с

## EDGE НА СТЕНДЕ ВЖИВУЮ

**4 × 4.8–4.9 к/с**
4 камеры одновременно: зона, СИЗ, падение, техника

**1.18 из 1.5**
ядра CPU контейнера заняты, RSS ~310 МБ

**0 откатов**
на CPU за 76 минут работы с таймаутом TPU 5 с

## НАРУЖУ — ТОЛЬКО СОБЫТИЯ

**11 КБ/с**
весь поток со стенда — 3–10 % канала VPN

**~25 КБ**
событие со снапшотом JPEG; без него ~0.8 КБ

**0.02 %**
метаданных кадров теряется по пути к шлюзу

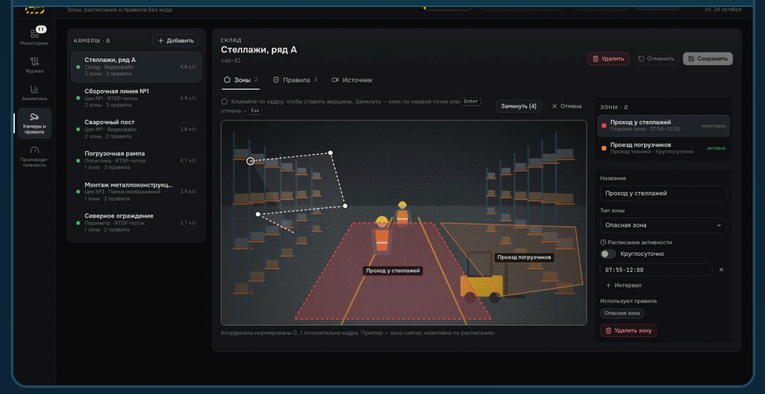
Источник: docs/ARCHITECTURE.md §1, §3 · решение D-005 · канал: docs/BENCHMARKS.md §4.2 · edge на стенде: docs/EDGE.md §6.1, §6.4 (замеры 24.10 10:02 и 13:38)

ЖИВОЕ ДЕМО П · О · UX

# Демо: 07:55 зона → 14:05 падение → отчёт

## 07:55 специалист ОТ

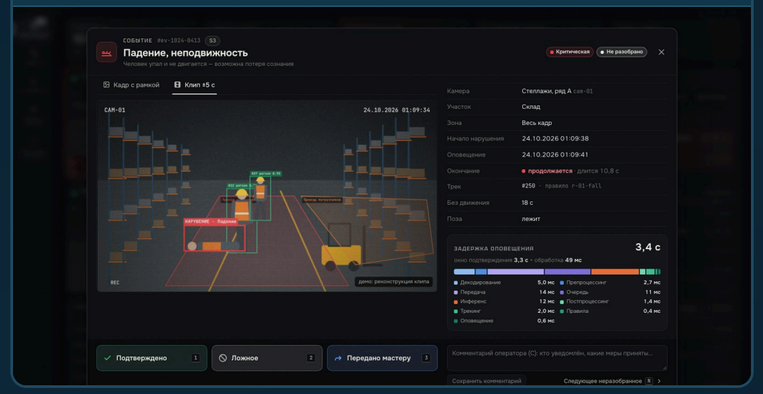
Камеры и правила · зона «Проход …




мок-режим UI Рисует зону мышью на кадре и ставит расписание «07:55–12:00» — без кода

## 14:05 мастер смены

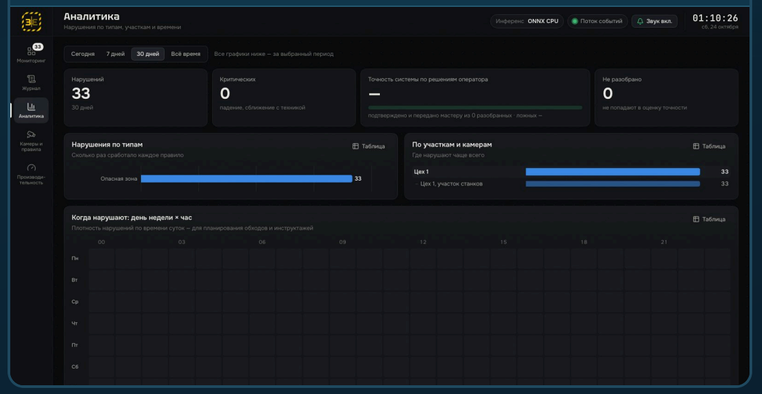
Карточка события · S3 «Падение, …




мок-режим UI Падение → критическая тревога со звуком: одна карточка с кадром и клипом ±5 с, клавиша 3 — мастеру

## Конец месяца менеджмент

Аналитика · по типам, участкам и…




живой бэкенд Где, когда и что нарушали; «день недели × час»; доля ложных по каждому правилу

### ВЖИВУЮ НА СТЕНДЕ LINQ

4 камеры — зона, СИЗ, падение, техника. Конвейер на edge рядом с TPU, шлюз и интерфейс — на ноутбуке. Оператор решает клавишами **1** подтверждено · **2** ложное · **3** передано мастеру

**2.2 с** p50 от начала нарушения до оповещения на ноутбуке · p95 2.5 с · 24.10 10:02

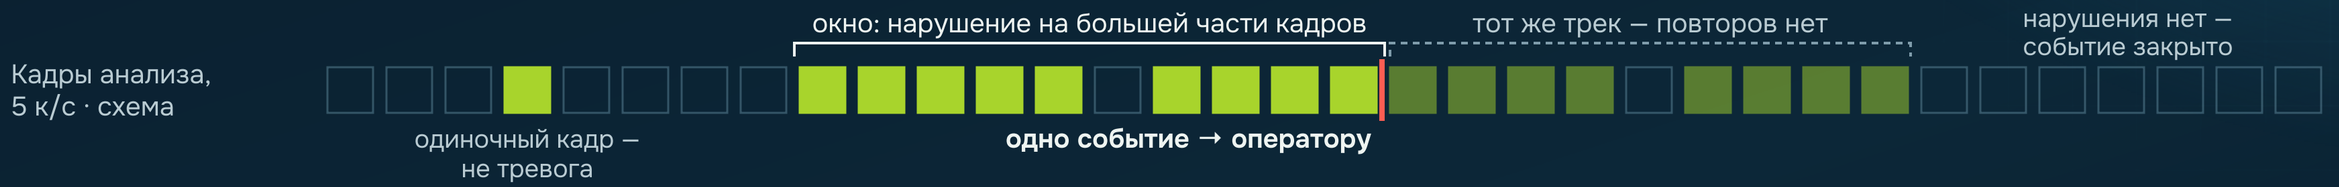
**будет обновлено к защите**

Резервное видео-демо: запись экрана с живыми событиями

Источник: Сквозной сценарий — кейс LinQ · скриншоты: deliverables/screens/05b, 02b — мок-режим UI; real-04 — живой бэкенд, local, CPU, 24.10 01:10 · задержка: docs/EDGE.md §6.1

СКОРОСТЬ И НАДЁЖНОСТЬ ОПОВЕЩЕНИЯ · О · В

# Одно нарушение — одно оповещение, без дублей




**01 Правило без памяти**
Плагин отвечает только «есть ли нарушение на этом кадре»

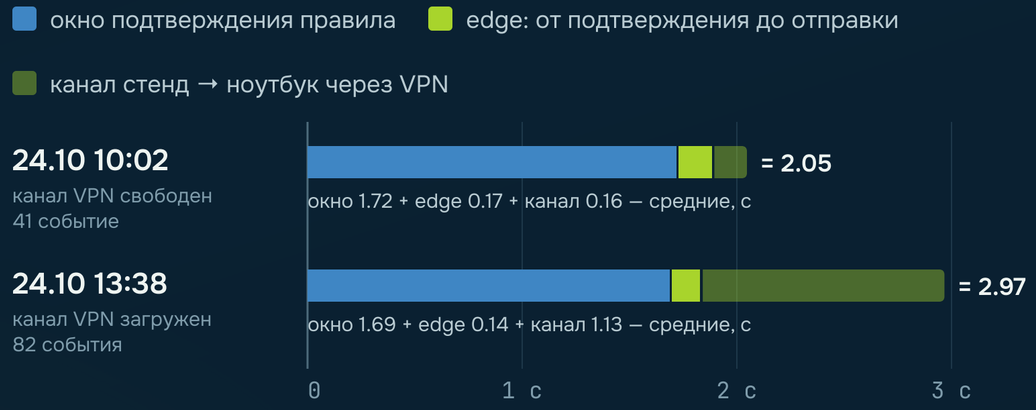
**02 Окно подтверждения**
Нарушение длится 1–2 с на большей части кадров окна

**03 Одно событие на трек**
Ключ — камера, правило, трек. Пока трек жив, повторов нет

**04 Дедуп при смене ID**
Рядом с недавним событием того же правила — не новое

**05 Осторожные правила**
«СИЗ не видно» — не нарушение; пороги подобраны под int8

## От начала нарушения до оповещения на ноутбуке, с




p50 / p95

**2.20** / 2.53

**2.84** / 4.05

TPU, 4 камеры, edge на стенде, шлюз на ноутбуке. Средние складываются в сквозную; справа — p50 и p95. Окно правила задаёт специалист ОТ, разброс даёт только VPN хакатона

## НА 13 РАЗМЕЧЕННЫХ РОЛИКАХ

**0** **дублей**
в базовой настройке — 2

**0** **ложных тревог на 535 с**
в базовой настройке — 3, все из-за жилета

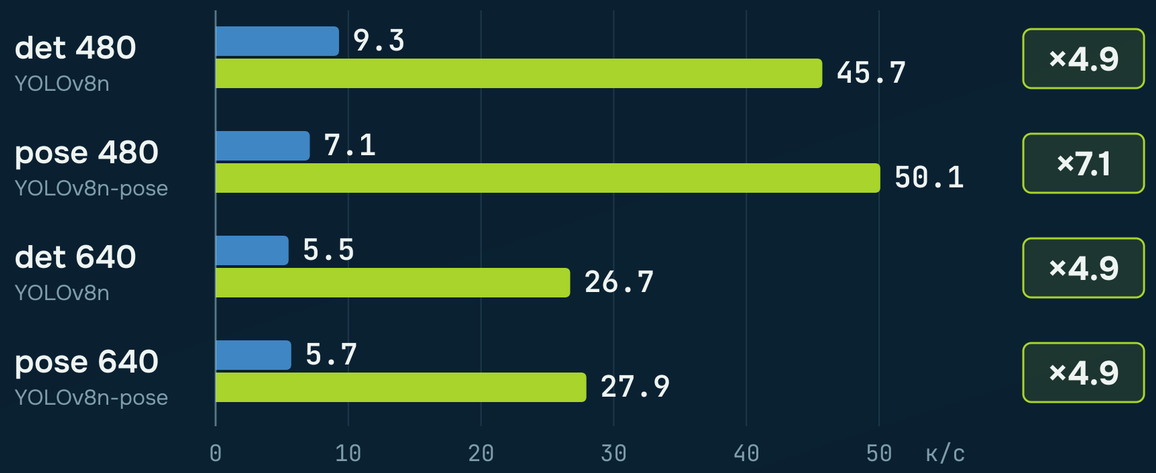
**2.35 с** **задержка p50 по всем типам**
офлайн-прогон всего конвейера

Источник: docs/ARCHITECTURE.md §5 · guard/events/manager.py · задержка: docs/EDGE.md §6.1, §6.4 — edge-tpu-20261024-1002.json, edge-tpu-stability-tap-20261024-1338.json · дубли и ложные: docs/QUALITY.md

LINQ TPU П·В·Н

# TPU даёт в 4.9-7.1 раза больше кадров/с, чем CPU

Кадров в секунду в одном контейнере (1.5 CPU, 4 ГиБ)




CPU — эквивалент 1000 / p50, лучший из двух прогонов; TPU — замер к/с

## ЧТО РЕШИЛИ НА ПЛАТФОРМЕ LINQ

01
### Raw-режим
Упаковка int8 на клиенте: в **1.9–2.3 раза** больше к/с, выходы совпадают бит в бит

02
### Срез головы YOLO
На TPU — основа сети, декод и NMS на CPU. Иначе int8 **обнуляет вероятности**

03
### Потолок Sigmoid
Калибровка срезала уверенность огня до **0.42–0.57**; порог 1.0 и пересборка её вернули

04
### Порог под int8
Уверенность на ~0.05 ниже: пороги 0.25–0.35, recall det **0.90 → 0.95**

## ЖИВОЙ EDGE, 4 КАМЕРЫ — ТОТ ЖЕ КОНВЕЙЕР

| | | |
|---|---|---|
| TPU | **19.4 к/с** | 4.8–4.9 к/с на камеру, все 4 типа событий подтверждаются |
| CPU | **4.8 к/с** | СИЗ — 0.29 к/с, падение — 0.92: за 240 с ни одного такого события |

## КАМЕР НА ОДИН TPU

N = ⌊ к/с конвейера / 5 к/с ⌋

**det 480**
зона, СИЗ, техника, бег
45.72 / 5 = 9.1
**9** камер

**det + pose 480**
падение, телефон, перелезание
21.06 / 5 = 4.2
**4** камеры

Точность int8 против CPU fp32 на кадрах сверки: recall 0.87–0.98, precision 0.93–1.00 (люди, поза, СИЗ, огонь). Узкое место — 1.5 CPU контейнера: TPU занят 8 мс из ~40

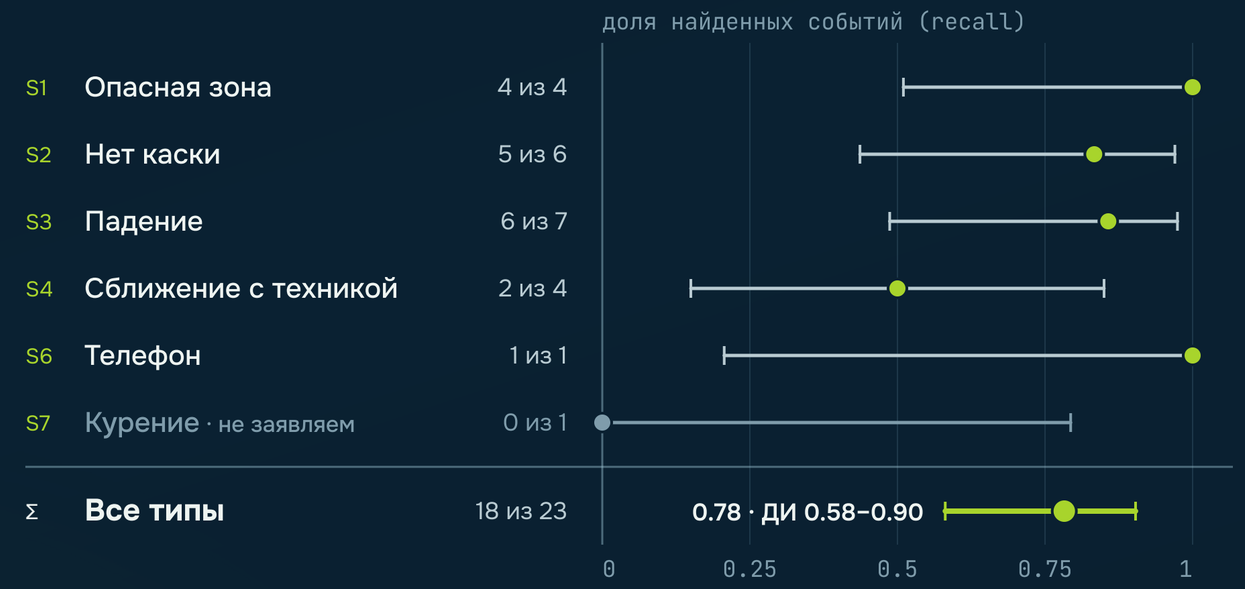
Источник: Замеры 24.10 00:52-01:55 и 09:50-10:20 МСК · контейнер стенда 1.5 CPU, 4 ГиБ · очередь TPU общая с другими командами · docs/BENCHMARKS.md §1-3, §5 · docs/LINQ_NOTES.md §13-17 · живой edge: docs/EDGE.md §6.3

КАЧЕСТВО — ЧЕСТНО · О · В · А

# На 13 роликах: precision 1.00, recall 0.78

| Precision | Recall | Дубли | Ложные тревоги | Задержка, p50 |
|---|---|---|---|---|
| **1.00** | **0.78** | **0** | **0** | **2.35 с** |
| 18 из 18 · 95 % ДИ 0.82–1.00 | 18 из 23 · 95 % ДИ 0.58–0.90 | в базовой настройке — 2 | на 535 с: скорее всего меньше ~20 в час | p95 8.85 с — из-за СИЗ |

Найдено событий по типам · точка — доля, линия — 95 % доверительный и…




## ОГРАНИЧЕНИЯ — ГОВОРИМ ЧЕСТНО

- **Мало событий:** 23 достоверных; одно событие — 4.3 п. п. полноты
- **0 ложных на 535 с** значит лишь «скорее всего меньше ~20 в час». Нужны часы видео с объекта
- **Подбор и оценка на одних роликах.** Защита: параметры общие для типа, середина устойчивого диапазона, стресс-тест — 0 ложных
- **Ролики стоковые,** часть склеена из сцен; реальных падений на производстве в открытых данных нет

## КАЧЕСТВО НА TPU В ЖИВОЙ КОНФИГУРАЦИИ

будет обновлено к защите

Сейчас все цифры качества получены на CPU: det 640 fp32. На TPU — те же 13 роликов: det и pose 480, СИЗ и огонь 640 в int8, пороги и правила стенда

| Precision | Recall | Ложные тревоги | Задержка p50 |
|---|---|---|---|
| — | — | — | — |

Источник: Офлайн-прогон всего конвейера, CPU, 24.10 13:42 · .orchestra/metrics/eval-onnx-cpu-phone-nearest-stress-20261024-1342.json · docs/QUALITY.md · 95 % ДИ — интервал Уилсона, расчёт по k и n

ЧТО УЛУЧШАЕМ · О·Н

# Слабые места → открытые наборы и дообучение

| СЦЕНАРИЙ | ПОЧЕМУ ОШИБАЕМСЯ | СЕЙЧАС | ОТКРЫТЫЕ НАБОРЫ | ПОСЛЕ ДООБУЧЕНИЯ |
|---|---|---|---|---|
| S4 **Сближение с погрузчиком** | погрузчика нет в классах моделей | 2 из 4 | Roboflow forklift (зеркало на HF); негативы — фуры, экскаваторы, самосвалы | будет обновлено к защите |
| S3 **Падение и неподвижность** | детектор теряет лежащего: падение с кровати, человек на снегу | 6 из 7 | UR Fall, CAUCAFall, Le2i, GMDCSA24 — без роликов оценки | будет обновлено к защите |
| S7 **Курение** | сигарету модель огня не видит | 0 из 1, не заявляем | наборы сигарет и курения (HF, Roboflow); авторазметка YOLO-World | будет обновлено к защите |
| S2 **Нет каски** | каску у людей в кадре с первой секунды видим поздно — до 18 с | 5 из 6, p95 задержки 16 с | SH17, обучающая часть Construction-PPE | будет обновлено к защите |

КАК МОДЕЛЬ ПОПАДАЕТ В ПРОДУКТ

открытый набор + сэмплы маховика → дообучение → ONNX → **программа LinQ TPU** → сверка с CPU → гейт на отложенных → карточка модели

**Отложенная выборка неприкосновенна.** Кадры 13 оценочных роликов и тестовые части наборов в обучение не попадают; падения делим по людям и сериям

**«До» и «после» — на одних данных.** Модель хуже базы не выкатываем: в карточке модели — статус rejected и причины

Источник: Слабые места: docs/QUALITY.md «Разбор ошибок», docs/DATASETS.md · решение D-006 · наборы — план, итог в docs/DATASETS.md · результаты: ml/model_cards/*.json

МАХОВИК ДАННЫХ Н · В · Э

# Замкнутый цикл качества: система сама собирает данные




Данные · маховик

будет обновлено к защите

Страница «Данные»: цикл из шести шагов, очередь проверки с рамками, датасеты, модели и решение гейта

будет обновлено к защите

Страница «Данные» влита в main и работает на мок-данных. Сбор сэмплов, API, авторазметка, дообучение и гейт — в работе

### ОТКУДА СЭМПЛЫ

- каждое событие и решение оператора по нему
- неуверенная детекция у порога правила, «мигание» трека
- расхождение TPU и CPU fp32 на выборочных кадрах
- кнопка «в выборку» у камеры, импорт открытых наборов

Сбор в фоне и не задерживает оповещение; на edge — до 10 КБ/с на камеру сверх потока событий

Источник: docs/FLYWHEEL.md — контракт маховика · решение D-007 · frontend/src/features/flywheel/ · ограничение трафика edge: docs/EDGE.md §6.1

РАСШИРЯЕМОСТЬ · B · UX

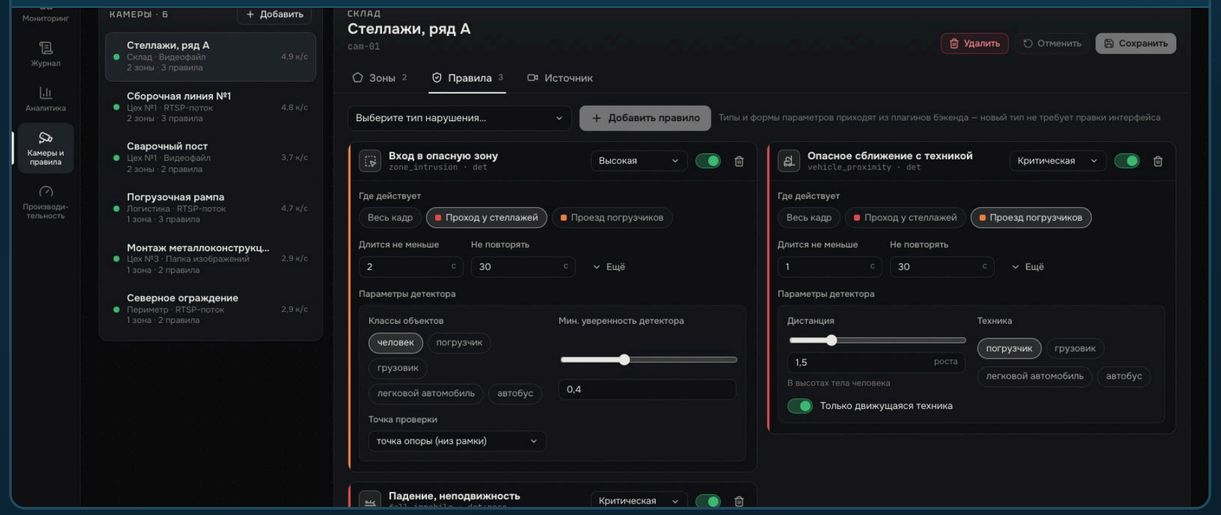
# Новый тип нарушения — один файл

crowding.py · пример из README, сокращено

```python
@register_rule
class CrowdingRule(RulePlugin):
    type = "crowding"
    title = "Скопление людей в зоне"
    required_models = frozenset({"det"})
    params_schema = {...}  # по ней UI строит форму

    def evaluate(self, ctx) -> list[Violation]:
        # только кадр; окно и дубли — в EventManager
        limit = int(self.cfg.params.get("max_people", 3))
        out = []
        for zone in self.camera.zones:
            if not is_zone_active(zone, ctx.ts):
                continue
            n = sum(in_zone(t, zone) for t in ctx.people)
            if n > limit:
                out.append(self.violation(ctx, zone_id=zone.zone_id))
        return out
```

Камеры и правила · формы правил из плагинов




мок-режим UI — Тип и форма параметров приходят из плагина — интерфейс не правим

**НОВОЕ НАРУШЕНИЕ**
файл в guard/rules/plugins/
в конвейере, API и UI — **ничего**

**НОВАЯ МОДЕЛЬ**
ONNX → программа TPU → строка в реестре
плагин просит её через **required_models**

**НОВЫЙ УСКОРИТЕЛЬ**
реализация InferenceBackend
выбор одной переменной: **onnx-cpu** или **linq-tpu**

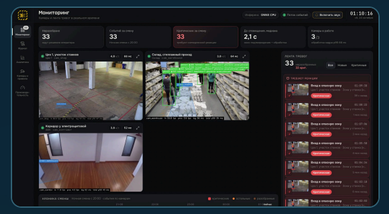
**ИНТЕГРАЦИИ**
подписчик на поток событий
СКУД, MES, мессенджеры, сигнал у зоны

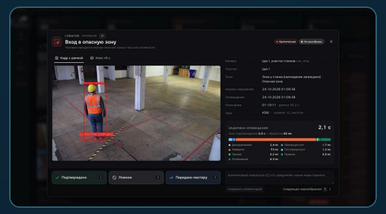
Источник: docs/ARCHITECTURE.md §6 · README.md «Как добавить новый тип нарушения» · guard/rules/plugins/ · скриншот 06-cameras-rules — мок-режим UI

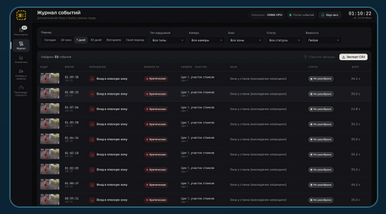
ИНТЕРФЕЙС ДЛЯ РОЛЕЙ КЕЙСА · UX · A

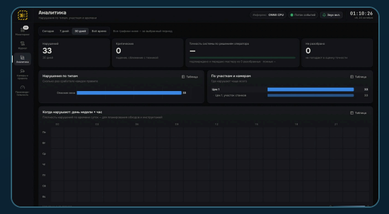
# Семь ролей кейса — у каждой свой экран и своя польза

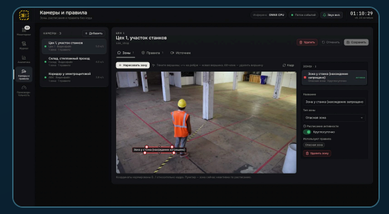
| РОЛЬ | БОЛЬ СЕЙЧАС | ЧТО ДАЁТ «ЗАЗЕРКАЛЬЕ» | ЭКРАН |
|---|---|---|---|
| 1 **Специалист по ОТ** | не может быть на всех участках | рисует зону на кадре, ставит расписание, включает правило формой | Камеры и правила |
| 2 **Мастер смены** | узнаёт о нарушении поздно или не узнаёт | одно оповещение с кадром, камерой и зоной; без повторов | Карточка события |
| 3 **Оператор, диспетчер** | внимание падает через 20–30 минут | лента вместо стены мониторов, критичные сверху; клавиши 1 / 2 / 3 | Мониторинг |
| 4 **Работники, водители** | контроль выборочный, «под проверку» | фиксация всегда и для всех одинаково; видео не покидает площадку | — косвенно |
| 5 **Служба ОТ, юристы** | нет визуальных доказательств | журнал: кадр, клип, решение и комментарий; фильтры, CSV | Журнал |
| 6 **Менеджмент** | нет статистики: где, когда, что | по типам, участкам, сменам; «день недели × час»; доля ложных | Аналитика |
| 7 **ИТ-служба, интеграторы** | сколько потоков выдержит железо | к/с и задержка по этапам, расчёт камер на TPU | Производительность |


Мониторинг


Карточка


Журнал


Аналитика


Камеры и правила


Производительность

**Покупает** служба ОТ / ПБ и менеджмент **Пользуются каждый день** диспетчер, мастер, специалист ОТ **Внедряет** ИТ-служба или интегратор

Источник: docs/ANALYTICS.md §1.1–1.2 · роли — кейс LinQ, слайды 9–12 · скриншоты real-* — живой бэкенд на ноутбуке, local, CPU, 24.10 ~01:10

ЭФФЕКТ И ЭКОНОМИКА · НА УСЛОВНЫХ ДОПУЩЕНИЯХ Э

# Пилот окупается, если предотвратить 0.6 инцидента в год

## ФАКТЫ С ИСТОЧНИКАМИ

**130-150 тыс. ₽**
штраф юрлицу за необеспечение СИЗ
ч. 4 ст. 5.27.1 КоАП РФ

**до 90 суток**
приостановки деятельности или 100–200 тыс. ₽ при повторном нарушении
ч. 5 ст. 5.27.1 КоАП РФ

**до 4 лет**
лишения свободы руководителю, если погиб человек
ст. 143 УК РФ

**46.1 человеко-дня**
нетрудоспособности на одного пострадавшего
Росстат, 2025

**120 000 ₽**
за видеопоток — ориентир цены ПО конкурента
VizorLabs Platform 3.0 Basic, от 5 потоков

## УСЛОВНЫЕ ДОПУЩЕНИЯ — ЗАМЕНИМ ДАННЫМИ ЗАКАЗЧИКА И ВЕНДОРА

| | | |
|---|---|---|
| Д-1 | edge-узел: сервер + ускоритель LinQ (цены в открытом доступе нет) | 1.5 млн ₽ |
| Д-2 | внедрение пилота: монтаж, зоны и правила, обучение | 0.5 млн ₽ |
| Д-3 | сопровождение: 20 % от Д-1 в год | 0.3 млн ₽/год |
| Д-4 | срок службы узла | 3 года |
| Д-5 | пилот: 8 камер — 2 узла при det + pose или 1 узел только с det | 8 камер |
| Д-6 | полная цена одного серьёзного инцидента для предприятия | 3 млн ₽ |

## В ГОД, МЛН ₽ — УСЛОВНО




(2×1.5 + 0.5)/3 + 2×0.3 ≈ 1.77, на камеру ≈ 0.22

## ПОРОГ ОКУПАЕМОСТИ

**≥ 0.6**

серьёзного инцидента в год (1.77 / 3.0) или **12 штрафов** по ч. 4 ст. 5.27.1. Только det — ≈ 0.33

Через месяц пилота Д-6 и долю пресечённых нарушений заменят данные журнала

Источник: docs/PITCH.md «Экономика внедрения» · КоАП РФ ст. 5.27.1, УК РФ ст. 143 (consultant.ru) · Росстат 2025 · vizorlabs.ru/tariffs · Д-n — условные допущения

АНАЛОГИ А · Н

# У аналогов отечественный ускоритель не заявлен

| ПРОДУКТ | ЧТО ДЕТЕКТИРУЕТ | ЖЕЛЕЗО ПО ОТКРЫТЫМ ДАННЫМ | ОТЕЧ. УСКОРИТЕЛЬ | «КАМЕР НА УЗЕЛ» |
|---|---|---|---|---|
| **Зазеркалье** | 10 типов: зоны, СИЗ, падение, техника, бег, телефон, огонь, ограждения, высота, груз | edge-узел с LinQ TPU: люди, поза, СИЗ, огонь в int8 | **да, замерено** | **по своим замерам** |
| **TRASSIR** DSSL | каска, жилет, опасные зоны | серверы NeuroStation; GPU не указан | не заявлен | — |
| **Macroscop** | каска, жилет, респиратор, очки, перчатки | NVIDIA с CUDA, от 4 ГБ памяти | не заявлен | — |
| **ITV** AxxonSoft | человек без экипировки: каски, жилеты | CPU, NVIDIA GPU, Intel GPU, Huawei NPU | не заявлен | — |
| **VizorLabs H&S** | СИЗ, зоны, техника, падение, огонь, курение | не указано; 120 000 ₽ за видеопоток | не заявлен | — |
| **SEES** JSA Group | СИЗ, опасные зоны, местоположение | ARM edge, x86, серверы с видеокартами | не заявлен | — |
| **Intenseye** | 50+ типов рисков, остановка станка через ПЛК | edge-блок на NVIDIA Jetson Orin NX | зарубежный | — |
| **Visionify** | 12 видов СИЗ, огонь, телефон, погрузчики | edge-сервер NVIDIA RTX A4000 | зарубежный | «до 10 камер» |

**ЧТО БЕРЁМ У ЛИДЕРОВ**

edge-обработка, наружу только события (Intenseye, Protex AI, Visionify) — наша схема устроена так же

**ЧЕМ ОТЛИЧАЕМСЯ**

LinQ TPU с открытыми замерами, одно оповещение на нарушение для всех 10 типов, замкнутый цикл качества

Источник: docs/ANALYTICS.md §3 — страницы продуктов проверены 24.10.2026, ссылки там же · «—» — в открытых источниках не указано

ДОРОЖНАЯ КАРТА Э·Н

# Прототип → пилот → масштаб узлами → интеграции

СЕЙЧАС

## Прототип на LinQ TPU

- Edge на стенде: 4 камеры, 10 плагинов
- Журнал, аналитика, редактор зон
- Маховик и дообучение — в работе

ШАГ 1

## Пилот на 2-3 опасных участках

- 1–2 узла LinQ, зоны настраивает специалист ОТ
- Маховик собирает кадры площадки, модели дообучаются под неё
- Журнал сам меряет эффект: пресечённые нарушения, доля ложных

ШАГ 2

## Масштаб узлами

- Число узлов — по формуле из замеров
- Шлюз сводит площадки в общий журнал
- Правка зон из UI сразу на узле, без рестарта

ШАГ 3

## Интеграции

- СКУД, MES, наряды-допуски, мессенджеры
- Световой и звуковой сигнал у зоны
- Отчёты по смене для службы ОТ

Источник: docs/PITCH.md · docs/ARCHITECTURE.md §6–7 · docs/ANALYTICS.md §3.2 · docs/FLYWHEEL.md · кейс LinQ, «Направления развития»

ИТОГ

# Одно нарушение — одно оповещение. На LinQ TPU.

главное

| | |
|---|---|
| **2.2 с** | от начала нарушения до оповещения, p50 на стенде LinQ |
| **1.00 / 0.78** | precision и recall на 13 размеченных роликах, 0 дублей |
| **×4.9–7.1** | кадров/с на TPU против CPU того же контейнера |
| **1 файл** | на новый тип нарушения; качество растёт через маховик данных |

ССЫЛКИ

github.com/timur-nagimov/mospromhack

- `README.md` запуск, сценарии, как добавить нарушение
- `docs/EDGE.md` edge на стенде, сквозная задержка
- `docs/QUALITY.md` качество и разбор каждой ошибки
- `docs/BENCHMARKS.md` замеры TPU, CPU и канала
- `docs/FLYWHEEL.md` маховик данных
- `docs/DATASETS.md` открытые наборы и дообучение

будет обновлено к защите

Резервное видео-демо: запись экрана с живыми событиями

Команда «Зазеркалье» · Хакатон «Открой#Моспром» · кейс LinQ

Источник: docs/EDGE.md §6.1 · docs/QUALITY.md · docs/BENCHMARKS.md · docs/FLYWHEEL.md

РЕЗЕРВ · ЗАМЕРЫ TPU

# Окна 1 / 4 / 8, raw и не-raw: откуда скорость




raw — ×1.9–2.3 при тех же выходах; окно 8 — ещё ×2 к окну 1

| МОДЕЛЬ, ВХОД | РЕЖИМ | К/С: ОКНО 1 / 4 / 8 | КАДР P50 / P95, МС | ИНФЕРЕНС P50 |
|---|---|---|---|---|
| det 480 | не-raw | 11.8 / 18.5 / 22.7 | 81.6 / 100.6 | 20.2 |
| det 480 | raw | **22.8 / 38.0 / 45.7** | 40.5 / 64.0 | 8.1 |
| det 640 | не-raw | 6.3 / 11.1 / 12.6 | 155.1 / 170.6 | 35.2 |
| det 640 | raw | **14.6 / 23.3 / 26.7** | 66.1 / 89.7 | 14.1 |
| pose 480 | raw | **24.1 / 44.7 / 50.1** | 39.4 / 60.2 | 8.2 |
| pose 640 | raw | **14.2 / 24.6 / 27.9** | 66.4 / 97.8 | 15.4 |
| det 480, срез conv | raw | 17.3 / 31.2 / 34.5 | 55.0 / 90.1 | 8.1 |

| DET + POSE НА КАЖДЫЙ КАДР, RAW | ОКНО 1 | БАТЧ 4 | БАТЧ 8 | БАТЧ 8 P50 / P95, МС |
|---|---|---|---|---|
| det 480 + pose 480 | 9.0 | 14.6 | **21.1** | 385 / 432 |
| det 640 + pose 640 | 5.9 | 10.4 | 12.1 | 625 / 821 |

Ошибок за прогоны нет. pose в режиме не-raw не мерили. Прогоны — ночью 24.10: инференс det 480 тогда 8 мс, утром в пике общей очереди — до 34 мс.

Источник: docs/BENCHMARKS.md §1 · ключи jupyter.tpu.* и jupyter.combo_det_pose_per_frame в .orchestra/metrics/tpu-baseline.json · 24.10 01:17–01:40 МСК

РЕЗЕРВ · ТОЧНОСТЬ INT8 НА TPU

# TPU int8 против CPU fp32: те же рамки, порог ниже

| МОДЕЛЬ | КАДРЫ СВЕРКИ | ДЕТЕКЦИЙ CPU | ПОРОГ TPU | RECALL / PRECISION | IOU СОВПАВШИХ | Δ УВЕРЕННОСТИ |
|---|---|---|---|---|---|---|
| **YOLOv8n det 480** | 30 отложенных, сценарии S1–S4 | 80 | 0.25 | **0.95 / 0.97** | 0.94 | -0.04 |
| **YOLOv8n-pose 480** | те же 30; ошибка точек 2.2 пикс. | 58 | 0.25 | **0.98 / 1.00** | 0.95 | -0.02 |
| **YOLOv8s СИЗ 640** | 43 кадра сценариев и образцов | 231 | 0.35 | **0.91 / 0.95** | 0.91 | -0.05 |
| **YOLOv8n огонь 640, s1** | 28: 13 с огнём, 15 без | 30 | 0.35 | **0.87 / 0.93** | 0.92 | -0.05 |

### СВЕРКА ОБЯЗАТЕЛЬНА

Precision и recall здесь — совпадение TPU с CPU той же модели (класс и IoU ⩾ 0.5), а не с разметкой. Каждую новую программу сверяем так же

### ПОТОЛОК SIGMOID

Масштаб выхода калибруется по максимуму на калибровочных кадрах. Огня в них почти не было: потолок 0.42 / 0.50 / 0.57 по страйдам. Порог слоя 1.0 → шаг уверенности 1/127, Δ -0.19 → -0.05

### ПОРОГ ПОД INT8

Уверенность после int8 ниже на 0.02–0.05. Порог det на TPU 0.25 вместо 0.35: recall 0.90 → 0.95 на отложенных кадрах. Дообучение квантования почти ничего не дало

Источник: docs/BENCHMARKS.md §3.1 · docs/LINQ_NOTES.md §16–17 · tpu/yolo_check.py, tpu/fix_thresholds.py · 24.10 01:55 и 09:50–10:20 МСК

РЕЗЕРВ · КАНАЛ «НОУТБУК ↔ СТЕНД»

# Почему конвейер стоит рядом с TPU (решение D-005)

| БРОКЕР И TPU | НОУТБУК, VPN | СЕРВЕР СТЕНДА |
|---|---|---|
| RTT до брокера, p50 / p95 | 235.5 / 363.7 мс | **1.04 / 98.4 мс** |
| Подключение AMQP | 2376 мс | 500 мс |
| Петля 0.1 МБ через брокер, p50 | 2116 мс | **1.76 мс** |
| Петля 1 МБ, p50 | 7955 мс | **104 мс** |
| Петля 5 МБ, p50 | 27 645 мс | **901 мс** |
| Скорость туда и обратно | 0.11–0.37 МБ/с | 11–278 МБ/с |
| resnet50 (пример организаторов), total p50 | 712 мс | 100.7 мс |
| YOLOv8n det 480 raw, total p50 | 3305 мс | **40.5 мс** |
| YOLOv8n det 480 raw, к/с | 0.29–0.33 | **22.8–45.7** |

| СТЕНД → НОУТБУК, СВОЯ ОЧЕРЕДЬ | P50 / P95 | ПОТОК |
|---|---|---|
| 64 Б, запрос-ответ | 237 / 308 мс | — |
| 2 КБ — событие и метаданные | **467 / 470 мс** | 42 сообщ./с |
| 60 КБ — снапшот JPEG | 703 / 1860 мс | 5.8 сообщ./с |

- Вход YOLO 480 в float32 — 2.76 МБ; обратный канал — 0.1–0.4 МБ/с
- Поэтому декод, TPU, трекинг и правила — на стенде, на шлюз — только события и метаданные
- Живое видео через канал не гоняем: шлюз проигрывает те же файлы, рамки рисует по метаданным
- В продукте это edge-узел на площадке: видео не покидает периметр

Источник: docs/BENCHMARKS.md §4 · ключи laptop.net, jupyter.net, laptop.channel_server_to_client · 24.10 00:52–01:26 МСК

РЕЗЕРВ · EDGE НА СТЕНДЕ

# Три прогона на TPU и один на CPU того же контейнера

| 4 КАМЕРЫ: ЗОНА, СИЗ, ПАДЕНИЕ, ТЕХНИКА | 10:02 · 300 С | 11:33 · 300 С | 13:38 · 600 С | CPU · 240 С |
|---|---|---|---|---|
| к/с на камеру, p50 | 4.81–4.88 | 4.54–4.86 | 4.85–4.90 | 0.29–1.84 |
| CPU контейнера, ядер из 1.5 | 1.18 | 1.11 | 1.12 | 1.50 |
| События: зона / техника / падение / СИЗ | 15 / 8 / 13 / 5 | 15 / 9 / 9 / 7 | 30 / 17 / 18 / 17 | 8 / 5 / 0 / 0 |
| Сквозная задержка p50 / p95, с | 2.20 / 2.53 | 2.30 / 2.99 | 2.84 / 4.05 | 3.02 / 3.56 |
| Из неё окно правила, p50, с | 1.71 | 1.62 | 1.60 | — |
| Канал стенд → ноутбук, p50, с | 0.15 | 0.36 | 1.02 | — |
| RTT ноутбук ↔ брокер, p50, мс | 228 | 273 | 386 | — |
| Потери метаданных кадров | 0.02 % | 0 % | 0 % | — |
| Откаты с TPU на CPU | 0 | 0 | 0 за 76 мин | — |

### ЧТО СЪЕДАЕТ ЗАДЕРЖКУ

Окно правила — 1.6–1.7 с, edge — 0.15 с во всех прогонах. Растёт только канал VPN: в 13:38 через тот же туннель шли выгрузки

### ЧТО ИСПРАВИЛИ ПО ЗАМЕРАМ

Шлюз брал сообщения по одному (prefetch 1): задержка 12.6 с. С prefetch 200 — 2.2 с. Таймаут TPU 2 → 5 с: было 13 откатов на CPU в час, стало 0

### ЧЕСТНОСТЬ ЗАМЕРА

Прогон 12:34 признан недостоверным: замер делил очередь со шлюзом демо. Повтор — с копией потока (13:38). Часы стенда и ноутбука сверены двумя способами

Источник: docs/EDGE.md §6.1-6.4, §7.1 · .orchestra/metrics/edge-tpu-20261024-1002.json, edge-tpu-20261024-1133.json, edge-tpu-stability-tap-20261024-1338.json, edge-cpu-20261024-1109.json

РЕЗЕРВ · КАЧЕСТВО ПОДРОБНО

# База → подбор параметров → оставшиеся ошибки

| 13 РОЛИКОВ, 23 СОБЫТИЯ | TP | FP | FN | ДУБЛИ | P | R | P50 |
|---|---|---|---|---|---|---|---|
| База, штатные параметры | 11 | 3 | 12 | 2 | 0.79 | 0.48 | 3.1 с |
| Итог: подбор + доработки | 18 | 0 | 5 | 0 | 1.00 | 0.78 | 2.35 с |

- Все 3 ложные базы — жилет на людях в спецовке. По умолчанию правило СИЗ проверяет каску, жилет — на зоне, где обязателен
- Тревога о падении — через 3.5 с вместо 7: люди на роликах лежат после падения 4–7 с
- Доработки трекинга и событий: история трека 8 с, одно падение — одно событие, телефон по ближайшей точке головы
- Около 900 вариантов параметров; взяты общие для типа и середина устойчивого диапазона. Стресс-тест на чужих роликах — 0 ложных

| ОСТАЛОСЬ 5 ПРОПУСКОВ | ПРИЧИНА | ЧТО ПОМОЖЕТ |
|---|---|---|
| Погрузчик ×2 | нет класса в моделях | детектор с forklift |
| Падение с кровати | лежащего видно урывками | дообучение на позах лёжа |
| Курение | сигарету модель огня не видит | детектор сигареты |
| Без каски на склейке | трек переживает монтаж ролика | сброс трекера при смене сцены |

### КАК СЧИТАЕМ

Событие совпало с меткой, если интервалы пересекаются с допуском 2 с. 10 спорных меток не идут ни в плюс, ни в минус. Задержка — от начала нарушения по разметке до оповещения

Источник: docs/QUALITY.md · eval-onnx-cpu-base-20261024-0913.json, eval-onnx-cpu-phone-nearest-stress-20261024-1342.json, eval-onnx-cpu-variants-20261024.json · ml/eval/scenarios.yaml

РЕЗЕРВ · ДАННЫЕ И МОДЕЛИ

# Только открытые данные; разметку событий сделали сами

| РОЛИКИ · 13 ШТ., 535 С | ЛИЦЕНЗИЯ | ШТ. |
|---|---|---|
| Intel IoT DevKit: цех с зоной за лентой, стеллажи | CC BY 4.0 | 2 |
| Intel safety-gear-detector: люди в касках и без | BSD-3 | 1 |
| Mixkit: склад, стройка, падение в снег, техника, телефон, курение, 2 «чистых» | Mixkit Free | 9 |
| GMDCSA24: склейка 6 постановочных падений | MIT | 1 |

- Разметка: начало и конец каждого нарушения — 23 достоверных события и 10 спорных; полигоны зон для 3 роликов
- Калибровка int8 — 200 кадров: стройка 60, склад 50, цех 60, демо-камеры 30. Тестовые кадры в неё не входят
- Набор воспроизводится скриптом с нуля, sha256 исходников сверяется

| МОДЕЛЬ | ДЛЯ ЧЕГО | КАК ВЫБРАЛИ |
|---|---|---|
| YOLOv8n 480 | люди, техника, телефон | самая лёгкая: 45.7 к/с на TPU |
| YOLOv8n-pose 480 | падение, телефон, перелезание | то же: 50.1 к/с |
| YOLOv8s СИЗ, 14 классов | каска, жилет, техника | лучшая из 6 открытых: AP50 каска 0.83, жилет 0.84 |
| YOLOv8n огонь и дым | открытый огонь | 9 из 10 кадров с огнём, 0 ложных на 10 без огня |

Веса YOLOv8 и найденных моделей — AGPL-3.0. Для коммерческого внедрения — дообучение на данных заказчика и лицензирование

Источник: docs/EXPERT_CALL.md §3 · docs/DATA.md · docs/MODELS.md · ссылки на источники и лицензии — там же

РЕЗЕРВ · СЦЕНАРИИ КЕЙСА

# Сценарии S1-S10: 10 плагинов, статус на 24.10, 14:00

| # | НАРУШЕНИЕ | ПЛАГИН | МОДЕЛИ | СТАТУС |
|---|---|---|---|---|
| S1 | Вход в опасную зону, с расписанием | zone_intrusion | det | ■ работает вживую на TPU в edge-режиме; на роликах 4 из 4 |
| S2 | Нет каски или жилета | ppe_missing | det + ppe | ■ работает на TPU в edge-режиме; 5 из 6. Жилет включается на зоне, где он обязателен |
| S3 | Падение и неподвижность | fall_immobile | det + pose | ■ работает на TPU в edge-режиме; 6 из 7 |
| S4 | Опасное сближение с техникой | vehicle_proximity | det | ■ работает на TPU в edge-режиме; 2 из 4 — погрузчика нет в классах, дообучение в работе |
| S5 | Бег в зоне работы техники | running | det | ■ плагин и тесты готовы, демо-ролика нет |
| S6 | Телефон при работе | phone_usage | det + pose | ■ плагин и тесты готовы; на ролике 1 из 1, на всех 13 роликах 0 ложных |
| S7 | Открытый огонь; курение не заявляем | smoking_fire | fire | □ модель огня на TPU, сверена с CPU; курение 0 из 1, детектор сигареты в работе |
| S8 | Перелезание через ограждение | fence_climb | det + pose | ■ плагин и тесты готовы, демо-ролика нет |
| S9 | Высота без привязи | height_no_harness | det | ■ осторожная эвристика: без модели привязи — контроль доступа в зону высоты |
| S10 | Переноска груза с нарушением | unsafe_carry | det + pose | ■ осторожные эвристики по позе, демо-ролика нет |

■ работает вживую на TPU □ модель или прогон в работе ■ плагин и тесты готовы

Источник: docs/EXPERT_CALL.md §4.4 · docs/QUALITY.md · docs/MODELS.md · guard/rules/plugins/

РЕЗЕРВ · ОГРАНИЧЕНИЯ И РИСКИ

# Что может помешать и что мы с этим делаем

| РИСК | ЧТО ДЕЛАЕМ |
|---|---|
| Очередь TPU общая с другими командами | инференс 8 мс ночью и до 34 мс в пике; цифры даём с датой; таймаут TPU 5 с |
| Контейнер стенда — 1.5 CPU, 4 ГиБ | субпоток 640×360, 2 потока ORT; в окна показа без компиляций и оценок |
| Канал VPN: 0.1–0.4 МБ/с от стенда | наружу только события, 11 КБ/с; во время показа — без выгрузок |
| Мало размеченных событий — 23 | интервалы показываем; маховик и отложенные наборы падений и курения |
| Подбор и оценка на одних роликах | параметры общие для типа, середина плато, стресс-тест — 0 ложных |
| СИЗ — десятки пикселей, задержка каски до 18 с | только явное «нет каски»; дообучение на SH17 — в работе |
| Правка зон из UI в режиме edge | на узел — после синхронизации и рестарта; канал конфигурации — в плане |
| Ноутбук падал по нехватке памяти | сторож памяти, тяжёлые задачи — строго по одной |

## МОДЕЛИ И ЛИЦЕНЗИИ

- YOLOv8n и YOLOv8n-pose (COCO), Ultralytics — AGPL-3.0
- СИЗ: construction-site-safety-hazards v0.3 (YOLOv8s), веса AGPL-3.0, данные CC BY 4.0
- Огонь и дым: fire-smoke-yolov8n (D-Fire), AGPL-3.0
- Открытые наборы для дообучения — внутреннее решение для демо: источник каждого записан, лицензии не проверяли
- Для внедрения — дообучение на данных заказчика и лицензирование

Источник: docs/EDGE.md §6.4, §7.2 · docs/QUALITY.md «Ограничения» · docs/BENCHMARKS.md · docs/EXPERT_CALL.md §5 · docs/MODELS.md

РЕЗЕРВ · ВОПРОСЫ

# Вопросы экспертам и организаторам

## ПРОДУКТ И КАЧЕСТВО

1. Что для заказчика важнее: не пропустить нарушение или не дать ложную тревогу? Сколько ложных тревог в час на камеру приемлемо?
2. Сигнальный жилет на ваших объектах обязателен всегда или только в отдельных зонах? Включать ли проверку жилета по умолчанию?
3. Есть ли у LinQ или партнёров реальные записи с производства, хотя бы несколько часов без нарушений? Это главный способ честно оценить ложные тревоги

## СТЕНД И ЗАЩИТА

4. Будут ли перезапуски Jupyter-контейнера или очистка /auto/cache во время защиты 25.10? Можно ли на это время поднять лимит контейнера (1.5 CPU, 4 ГиБ)?
5. Что входит в inference_time воркера? Сколько TPU-устройств обслуживают общую очередь?
6. Канал VPN асимметричный: к стенду 1–2 МБ/с, от стенда 0.1–0.4 МБ/с. Это ограничение сервера? Есть ли UDP-профиль?

Источник: docs/EXPERT_CALL.md §6 · .orchestra/QUESTIONS_FOR_ORGS.md · список правится в data.json → questions